TECNOLÓGICO NACIONAL DE MÉXICO

INSTITUTO TECNOLÓGICO DE HERMOSILLO

Actividad: Proyecto final.

Materia: Aprendizaje automático II.

Alumno: García Gutiérrez Juan Alberto.

Maestro: Hinojosa Palafox Eduardo Antonio.

Hermosillo, Sonora a 11 de diciembre de 2022

2. Introducción

Este proyecto final plantea el resolver una problemática sobre una situación desde la perspectiva del aprendizaje automático, a lo largo del curso de Aprendizaje automático II se realizaron distintos algoritmos y modelos que permiten darle solución a distintas problemáticas realizando predicciones para conocer el resultado que se obtendrá en base al comportamiento que han tenido sus similares.

Una predicción permite prevenir distintos percances y/o situaciones, gracias a la implementación de distintos modelos como Random Forest o Regresión logística es posible obtenerlas y según su porcentaje de precisión seleccionar el modelo más óptimo para la situación, cabe señalar que no solo existen estos dos mencionados anteriormente, existen una cantidad amplia, los cuales para cada problemática se adapta de mejor manera uno en específico.

En este proyecto, se dio solución al pronóstico de lluvia de un dia posterior en base a los datos del dataset en el país de Australia, debido a las distintas problemáticas que han surgido con el cambio climático, el clima es muy variado en muchos países del mundo, uno de estos es Australia, donde a llegado el punto de variar mucho los pronósticos de lluvia en base a años anteriores. Para ello, se utilizaron los conocimientos proporcionados y formalizados en la materia de aprendizaje automático II, dando como resultado una predicción certera.

3. Descripción del problema a desarrollar

Australia al igual que muchos de los países del mundo, en los últimos tiempos ha presentado muchas variaciones en su clima, perteneciendo al grupo de países que sufren un cambio climático. En comparación con años anteriores, Australia contaba con un clima cálido y templado en su mayoría, presentando lluvias ocasionales que le permitían realizar las tareas comunes del país.
A raíz del cambio climático los días con lluvia han variado, teniendo días donde se presenta mucha lluvia y mismos que son muy seguidos, por lo que el exceso de agua en ocasiones no se puede controlar. Me he planteado el recopilar un dataset con la información de las últimas lluvias que ha tenido este país y aplicar una preprocesamiento de los datos para que me permita aplicar un modelo y este me proporcione la información necesaria para determinar predicciones tanto de entrenamiento como de prueba sobre si lloverá el día de mañana en base a los datos del dataset.

4. Descripción del conjunto de datos

El conjunto de datos fue obtenido en Kaggle dataset, este dataset proporciona distintas características respecto al clima de Australia, mismos que permiten realizar los procedimientos adecuados para generar las predicciones pertinentes y determinar si lloverá el día de mañana en base a los datos del dataset.

Se cuenta con los datos registrados en relación a la lluvia que competen del año 2008 al años 2017, entre sus características se observan datos como la fecha, locación, mínimo y máximo de temperatura, nubosidad, entre otras más.

	Date	Location	MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine	WindGustDir	WindGustSpeed	WindDir9am	...	Humidity9am	Humidity3pm	Pressure9am	Pressure3pm	Cloud9am	Cloud3pm	Temp9am
0	2008-12-01	Albury	13.4	22.9	0.6	NaN	NaN	W	44.0	W	...	71.0	22.0	1007.7	1007.1	8.0	NaN	16.9
1	2008-12-02	Albury	7.4	25.1	0.0	NaN	NaN	WNW	44.0	NNW	...	44.0	25.0	1010.6	1007.8	NaN	NaN	17.2
2	2008-12-03	Albury	12.9	25.7	0.0	NaN	NaN	WSW	46.0	W	...	38.0	30.0	1007.6	1008.7	NaN	2.0	21.0
3	2008-12-04	Albury	9.2	28.0	0.0	NaN	NaN	NE	24.0	SE	...	45.0	16.0	1017.6	1012.8	NaN	NaN	18.1
4	2008-12-05	Albury	17.5	32.3	1.0	NaN	NaN	W	41.0	ENE	...	82.0	33.0	1010.8	1006.0	7.0	8.0	17.8

5. Descripción de la solución propuesta.

Para desarrollar una solución de manera eficiente, he tomado la decisión de implementar dos modelos vistos en el curso, para determinar cuál es el más óptimo a implementar en esta situación en base a la precisión que resulte de cada uno de ellos. Los modelos seleccionados fueron regresión logística y Random Forest, si es el caso de obtener un porcentaje muy bajo, se realizará la implementación de otros modelos.

El objetivo de esta solución propuesta, es realizar predicciones de entrenamiento y prueba que determinen si lloverá o no el día de mañana basándose en los datos proporcionados en el dataset.

6. Descripción del código utilizado

Como primera instancia, se importaron las librerías pertinentes para este proyecto, entre las cuales se encuentran pandas, matplotlib, seaborn, sklearn y SMOTE, esta última, fue utilizada para balancear datos cuando estos presentan un desbalance considerable.

García Gutiérrez Juan Alberto 18330437

Librerias y cargar dataset

```
[1]  import pandas as pd
     import matplotlib.pyplot as plt
     import seaborn as sns
     import plotly.express as px
     from sklearn.preprocessing import LabelEncoder

     from scipy.stats import zscore
     from sklearn.metrics import classification_report
     from sklearn.linear_model import LogisticRegression
     from sklearn.ensemble import RandomForestClassifier

     from sklearn.metrics import accuracy_score
     from sklearn.model_selection import train_test_split
     from imblearn.over_sampling import SMOTE
```

Ahora, se cargan en un dataframe el conjunto de datos, cabe señalar que para un mejor manejo, se utilizó parse_dates en la columna Date, que ayuda a convertir los datos de esa columna en formato de fecha si no lo están.

```
data_clima=pd.read_csv('weatherAUS.csv',parse_dates=['Date'])
data_clima.head()
```

	Date	Location	MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine	WindGustDir	WindGustSpeed	WindDir9am	...
0	2008-12-01	Albury	13.4	22.9	0.6	NaN	NaN	W	44.0	W	...
1	2008-12-02	Albury	7.4	25.1	0.0	NaN	NaN	WNW	44.0	NNW	...
2	2008-12-03	Albury	12.9	25.7	0.0	NaN	NaN	WSW	46.0	W	...
3	2008-12-04	Albury	9.2	28.0	0.0	NaN	NaN	NE	24.0	SE	...
4	2008-12-05	Albury	17.5	32.3	1.0	NaN	NaN	W	41.0	ENE	...

5 rows × 23 columns

Se realizó un búsqueda de los datos periodos (nulos), realizando una suma de ellos para verificar las columnas donde estos datos son bastantes grandes, se utilizó isnull() y sum() para esto.
Además, para verificar la cantidad de filas y columnas antes de la eliminación de los nulos, se aplicó un shape(), dando como resultado un total de 145,460 filas y 23 columnas.

```
Preprocesamiento de los datos

Búsqueda de datos perdidos

[3]  data_clima.isnull().sum()

Date                0
Location            0
MinTemp          1485
MaxTemp          1261
Rainfall         3261
Evaporation     62790
Sunshine        69835
WindGustDir     10326
WindGustSpeed   10263
WindDir9am      10566
WindDir3pm       4228
WindSpeed9am     1767
WindSpeed3pm     3062
Humidity9am      2654
Humidity3pm      4507
Pressure9am     15065
Pressure3pm     15028
Cloud9am        55888
Cloud3pm        59358
Temp9am          1767
Temp3pm          3609
RainToday        3261
RainTomorrow     3267
dtype: int64

[4]  data_clima.shape

(145460, 23)
```

Se visualizaron 4 columnas que sobrepasan un promedio de valores nulos, por ello, se decidió eliminar dichas columnas, además de locación para generalizar el modelo y se utilizó de nuevo shape(), indicando que se tiene la misma cantidad de filas pero el número de columnas se redujo a 18.

```
[5]  data_clima.drop(['Evaporation','Sunshine','Cloud9am','Cloud3pm','Location'],axis=1,inplace=True)

[6]  data_clima.shape

(145460, 18)
```

Ahora, se rellenaron los valores nulos con los valores promedios en donde si se encuentran medio de una función, misma que se aplicó a un nuevo data frame, el cual contiene los datos del dataset original con el filtro de nulos previamente desarrollado.
De nueva cuenta, aplicamos isnull() y sum() solo que ahora para el nuevo dataframe y se observa que ya no existe ningún valor nulo.

```
#Rellenamos los valores nulos con los valores promedios en donde si se encuentran
def rellenar(info):
    columnas=info.columns
    for col in columnas:
        if info[col].dtype=='object':
            info[col].fillna(method='ffill',inplace=True)
        else:
            info[col].fillna(info[col].median(),inplace=True)
    return info
```

```
[8] data_filtro=rellenar(data_clima)
```

```
[9] data_filtro.isnull().sum()
```

```
Date             0
MinTemp          0
MaxTemp          0
Rainfall         0
WindGustDir      0
WindGustSpeed    0
WindDir9am       0
WindDir3pm       0
WindSpeed9am     0
WindSpeed3pm     0
Humidity9am      0
Humidity3pm      0
Pressure9am      0
Pressure3pm      0
Temp9am          0
Temp3pm          0
RainToday        0
RainTomorrow     0
dtype: int64
```

Se asignó la cantidad de datos de entrenamiento y prueba.

Asignación de valores de prueba y entrenamiento

```
[37] train_data,test_data=train_test_split(data_filtro,test_size=0.2,random_state=40)
```

Se recopiló en un array las columnas con datos categóricos del dataframe por medio de un for, dichas columnas se les aplicó LabelEncoder tanto en datos de entrenamiento como de prueba para darles valores entre 0 y 1.

Categóricas

```
[11] categoricas=[]
     columnas_num=[]
     for col in data_filtro.columns:
         if data_filtro[col].dtype=='object':
             categoricas.append(col)
         else:
             columnas_num.append(col)
     categoricas
```

```
['WindGustDir', 'WindDir9am', 'WindDir3pm', 'RainToday', 'RainTomorrow']
```

```
[12] encoder=LabelEncoder()
     train_data.WindGustDir=encoder.fit_transform(train_data.WindGustDir)
     test_data.WindGustDir=encoder.transform(test_data.WindGustDir)
     for col in categoricas[1:3]:
         train_data[col]=encoder.fit_transform(train_data[col])
         test_data[col]=encoder.transform(test_data[col])
```

Para visualizar si realiza una proporción balanceada sobre si lloverá hoy en específico, se utilizó una gráfica de tipo bar.

```
[13] px.bar(data_frame=train_data,x=train_data.RainToday.value_counts().index.values,y=train_data.RainToday.value_counts(),
         color=['No','Si'],title='¿Lloverá hoy?')
```

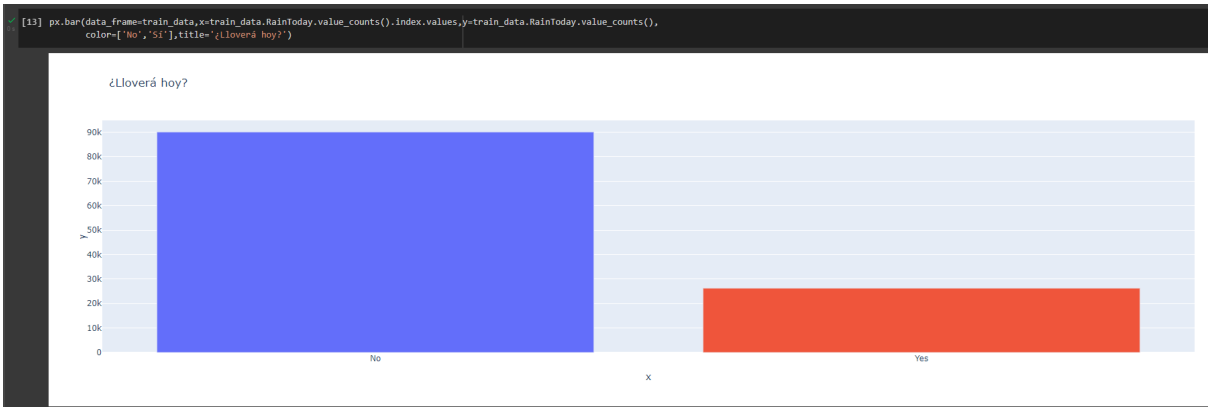

De igual forma, sobre si lloverá mañana, como se puede observar en ambos casos la proporción es muy variada, teniendo un gran desbalance.

```
[14] px.bar(data_frame=train_data,x=train_data.RainTomorrow.value_counts().index.values,y=train_data.RainTomorrow.value_counts(),
         color=['No','Si'],title='¿Lloverá mañana?')
```

De igual forma que con las columnas categóricas, se generó una recopilación de las variables numéricas y con describe(), de la cual se obtuvo una descripción de los datos de entrenamiento.

Numéricas

```
[15] # Numerical columns
     columnas_num

['Date',
 'MinTemp',
 'MaxTemp',
 'Rainfall',
 'WindGustSpeed',
 'WindSpeed9am',
 'WindSpeed3pm',
 'Humidity9am',
 'Humidity3pm',
 'Pressure9am',
 'Pressure3pm',
 'Temp9am',
 'Temp3pm']
```

```
[16] train_data.describe()
```

	MinTemp	MaxTemp	Rainfall	WindGustDir	WindGustSpeed	WindDir9am	WindDir3pm	WindSpeed9am	WindSpeed3pm	Humidity9am	Humidity3pm	Pressure9am	Pressure3pm	Temp9am	Temp3pm
count	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000	116368.000000
mean	12.186697	23.209176	2.332646	7.978052	39.955125	7.327031	7.817922	14.043294	18.669342	68.913627	51.556966	1017.640890	1015.246796	16.979626	21.664342
std	6.358890	7.087014	8.495613	4.682011	13.104732	4.524088	4.584200	8.867852	8.707922	18.851740	20.468450	6.730806	6.666730	6.446216	6.849702
min	-8.500000	-4.800000	0.000000	0.000000	6.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	982.000000	978.200000	-7.200000	-5.400000
25%	7.700000	18.000000	0.000000	4.000000	31.000000	3.000000	4.000000	7.000000	13.000000	57.000000	37.000000	1013.500000	1011.100000	12.300000	16.700000
50%	12.000000	22.600000	0.000000	8.000000	39.000000	7.000000	8.000000	13.000000	19.000000	70.000000	52.000000	1017.600000	1015.200000	16.700000	21.100000
75%	16.800000	28.200000	0.600000	12.000000	46.000000	11.000000	12.000000	19.000000	24.000000	83.000000	65.000000	1021.800000	1019.400000	21.500000	26.200000
max	33.900000	48.100000	371.000000	15.000000	135.000000	15.000000	15.000000	130.000000	83.000000	100.000000	100.000000	1041.000000	1039.600000	40.200000	46.200000

Al encontrar valores outliers se eliminaron las filas con Z score superior a 3 o inferior a -3, Z score indica la cantidad de desviaciones estándar en que se encuentra un valor de la media y de igual forma se aplicó LabelEncoder para los datos de entrenamiento y prueba, solo que ahora en los numéricos.

```
[38] #Eliminación de filas con puntuación Z Score superior a 3 o inferior a -3.

     datafiltro_train=train_data[abs(zscore(train_data.Rainfall))<3]
```

```
prediction_encoder=LabelEncoder()
datafiltro_train.RainToday=prediction_encoder.fit_transform(datafiltro_train.RainToday)
datafiltro_train.RainTomorrow=prediction_encoder.transform(datafiltro_train.RainTomorrow)

test_data.RainToday=prediction_encoder.transform(test_data.RainToday)
test_data.RainTomorrow=prediction_encoder.transform(test_data.RainTomorrow)
```

Como se observa, todos los datos de entrenamiento del dataframe son numéricos, a excepción de la fecha.

```
[19] datafiltro_train
```

	Date	MinTemp	MaxTemp	Rainfall	WindGustDir	WindGustSpeed	WindDir9am	WindDir3pm	WindSpeed9am	WindSpeed3pm	Humidity9am	Humidity3pm	Pressure9am	Pressure3pm	Temp9am	Temp3pm	RainToday	RainTomorrow
53108	2011-11-12	5.8	17.1	0.0	12	39.0	15	15	13.0	11.0	77.0	41.0	1017.6	1015.2	8.8	16.6	0	0
29920	2016-10-13	10.3	19.8	0.0	9	44.0	11	9	22.0	28.0	51.0	46.0	1021.9	1021.6	14.9	18.7	0	0
24240	2009-03-23	15.9	30.7	0.0	4	31.0	8	1	11.0	9.0	89.0	37.0	1017.6	1015.2	19.0	30.3	0	0
117187	2016-04-10	17.2	27.0	14.2	0	59.0	0	0	35.0	28.0	67.0	53.0	1020.2	1018.0	20.7	26.3	1	0
139487	2009-07-12	18.8	30.1	0.0	1	37.0	0	6	19.0	22.0	63.0	55.0	1012.7	1009.6	24.4	29.3	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
56760	2013-09-13	1.1	10.2	0.2	5	50.0	5	5	35.0	28.0	59.0	69.0	1016.4	1013.8	7.7	8.1	0	1
93176	2017-03-14	21.4	27.1	2.2	10	57.0	2	10	20.0	43.0	84.0	74.0	1016.4	1014.4	25.8	25.6	1	1
30727	2009-08-05	7.6	19.3	0.0	13	39.0	13	2	17.0	15.0	69.0	40.0	1022.8	1020.4	10.5	17.5	0	0
112859	2012-07-02	9.3	19.2	0.0	3	33.0	5	5	9.0	17.0	70.0	52.0	1028.3	1025.6	13.5	18.2	0	0
142662	2014-02-22	19.6	34.5	0.0	2	33.0	10	9	9.0	13.0	82.0	45.0	1009.7	1006.3	25.0	34.1	0	0

Para eliminar la fecha, se dropeo la columna Date, indicando axis = 1 y un inplace verdadero.

```
[20] datafiltro_train.drop(['Date'],axis=1,inplace=True)
```

Se verificó la correlación a través de un mapa de calor

```
# Se verifica la correlación
plt.figure(figsize=(20,20))
sns.heatmap(datafiltro_train.corr(),annot=True,vmin=-1)
plt.show()
```

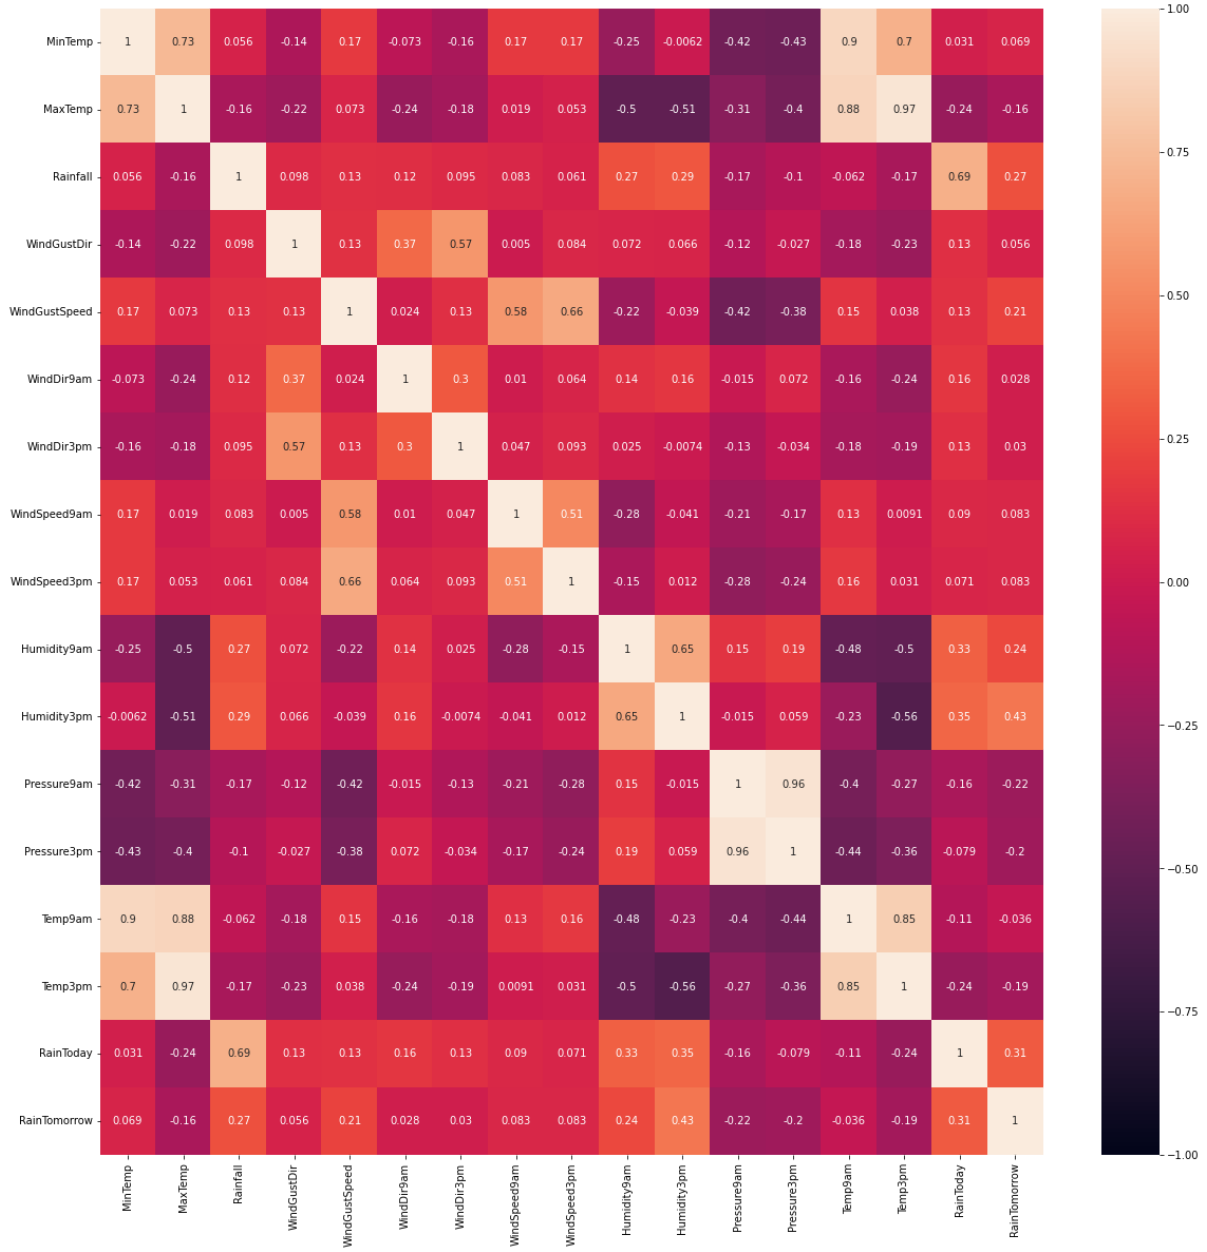

Algunas de las características se encuentran muy correlacionadas con otras, por ello, se eliminarán las correlaciones mayores a 0.7.

```
[22] datafiltro_train.drop(['MinTemp','MaxTemp','Temp9am','Pressure3pm'],inplace=True,axis=1)

[23] test_data.drop(['MinTemp','MaxTemp','Temp9am','Pressure3pm','Date'],inplace=True,axis=1)
```

Para solucionar el desbalance entre los datos, se utiliza SMOTE, el cual equilibra la distribución de clases aumentando aleatoriamente los ejemplos de clases minoritarias al replicarlos. Para comprobar que SMOTE realizó el balance correctamente, se verificó por medio de un gráfico de pie.

```
oversample=SMOTE()
train_inputs,train_output=oversample.fit_resample(datafiltro_train.drop(['RainToday'],axis=1),datafiltro_train.RainToday)

[25] fig=px.pie(train_output,names=prediction_encoder.inverse_transform([0,1]),values=train_output.value_counts(),
        hole=0.3,title='¿Lloverá hoy?')
     fig.show()
```

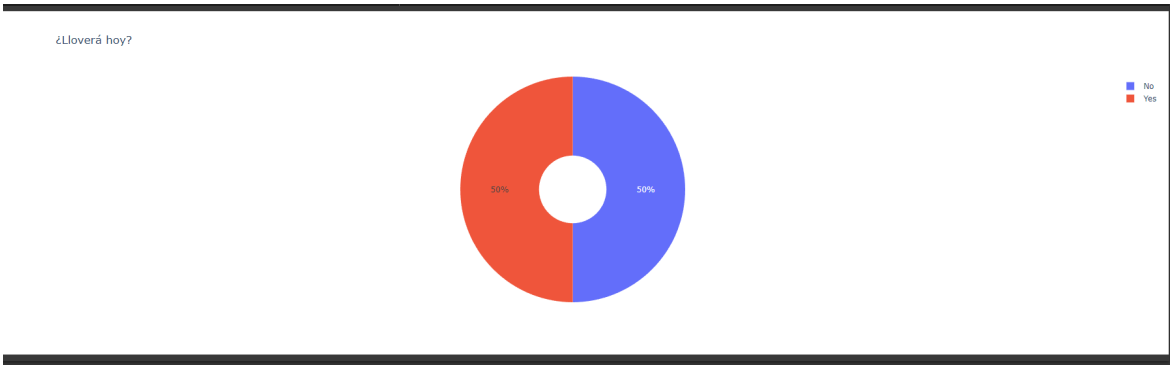

Se generaron los valores de train y test, son 2 debido a que uno se utilizó al final para responder a la pregunta precisa sobre si ¿Lloverá mañana? en base a los datos del dataset.

```
train_x,train_y1,train_y2=train_inputs.iloc[:,:11],train_output,train_inputs.iloc[:,11]
test_x,test_y1,test_y2=test_data.iloc[:,:11],test_data.iloc[:,11],test_data.iloc[:,12]
```

Modelos

Modelo de regresión logística

Se creó el modelo y se entrena

```
[27] modelLR=LogisticRegression()
     modelLR.fit(train_x,train_y1)
```

Se generó un reporte de clasificación de los datos de entrenamiento y prueba, obteniendo resultados muy apegados a 1, por lo que en es un buen modelo para esta situación.

```
print('Reporte de clasificación de training data\n',classification_report(train_y1,modelLR.predict(train_x)))
print('Reporte de clasificación de prueba data\n',classification_report(test_y1,modelLR.predict(test_x)))
```

```
Reporte de clasificación de training data
              precision    recall  f1-score   support

           0       0.98      0.98      0.98     90096
           1       0.98      0.98      0.98     90096

    accuracy                           0.98    180192
   macro avg       0.98      0.98      0.98    180192
weighted avg       0.98      0.98      0.98    180192

Reporte de clasificación de prueba data
              precision    recall  f1-score   support

           0       0.99      0.98      0.99     22602
           1       0.95      0.97      0.96      6490

    accuracy                           0.98     29092
   macro avg       0.97      0.98      0.97     29092
weighted avg       0.98      0.98      0.98     29092
```

Los resultados de la precisión de entrenamiento y prueba de regresión logística fueron de 98.06 y 98.16 respectivamente, lo que indicó que es un buen modelo, ya que se encuentra muy cerca del 100%.

```
[29] print('La precision de train de Regresión Logística es {0} %'.format((accuracy_score(train_y1,modelLR.predict(train_x))*100).round(2)))
     print('La precisión de prueba de Regresión Logística es {0} %'.format((accuracy_score(test_y1,modelLR.predict(test_x))*100).round(2)))

     La precision de train de Regresión Logística es 98.06 %
     La precisión de prueba de Regresión Logística es 98.16 %
```

Modelo Random Forest

Se generó y entrenó el modelo, con max_depth se le indicó la profundidad máxima, en este caso se seleccionó un valor de 8.

```
[37] model_random_forest=RandomForestClassifier(max_depth=8)
     model_random_forest.fit(train_x,train_y1)
     RandomForestClassifier(max_depth=8)

     RandomForestClassifier(max_depth=8)
```

Se generó un reporte de clasificación de los datos de entrenamiento y prueba, donde se obtuvieron resultados más apegados a 1 en comparación con el anterior modelo, por que en es el mejor modelo para esta situación.

```
[38] print('Reporte de clasificación de training data\n',classification_report(train_y1,model_random_forest.predict(train_x)))
     print('Reporte de clasificación de prueba data\n',classification_report(test_y1,model_random_forest.predict(test_x)))

     Reporte de clasificación de training data
                   precision    recall  f1-score   support

                0       0.98      1.00      0.99     90096
                1       1.00      0.98      0.99     90096

         accuracy                           0.99    180192
        macro avg       0.99      0.99      0.99    180192
     weighted avg       0.99      0.99      0.99    180192

     Reporte de clasificación de prueba data
                   precision    recall  f1-score   support

                0       0.99      1.00      1.00     22602
                1       1.00      0.97      0.99      6490

         accuracy                           0.99     29092
        macro avg       1.00      0.99      0.99     29092
     weighted avg       0.99      0.99      0.99     29092
```

Los resultados de la precisión de entrenamiento y prueba de random forest fueron de 98.76 y 99.37 respectivamente, lo que indicó que es el mejor modelo para aplicar en comparación con regresión logística, ya que se encuentra más cerca del 100%.

```
print('La precisición de train de Random Forest es {0} %'.format((accuracy_score(train_y1,model_random_forest.predict(train_x))*100).round(2)))
print('La precisión de validación de Random Forest es {0} %'.format((accuracy_score(test_y1,model_random_forest.predict(test_x))*100).round(2)))

La precisición de train de Random Forest es 98.76 %
La precisión de validación de Random Forest es 99.37 %
```

7. Resultados

Una vez seleccionado el mejor modelo, se aplicó para darle solución a la problemática y verificar si lloverá mañana en base a los datos proporcionados en el dataset.

Como recordamos al momento de aplicar SMOTE, se generaron 2 valores de y, estos fueron para utilizarlos para determinar las predicciones en esta sección, tomando estos valores se creó una Series, que permitió almacenar información de diversa tipología, así como también se aplicó un reset_index para restablecer el índice.

```
[33] train_x2=pd.concat([train_x,train_y1],axis=1)

[34] test_y1_pred=pd.Series(model_random_forest.predict(test_x),name='RainToday')
     test_x2=pd.concat([test_x.reset_index(drop=True),test_y1_pred.reset_index(drop=True)],axis=1)
```

Se creó el modelo que permitió obtener las predicciones y de igual forma se entrenó.

```
[35] model_random_forest2=RandomForestClassifier()
     model_random_forest2.fit(train_x2,train_y2)

     RandomForestClassifier()
```

La precisión de entrenamiento sobre si lloverá mañana en base al conjunto de datos fue de 99.98% y de prueba de 84.06%.

```
[36] print('La precisión de train para predecir si lloverá mañana es {0} %'.format((accuracy_score(train_y2,model_random_forest2.predict(train_x2))*100).round(2)))
     print('La precisión de prueba para predecir si lloverá mañana es {0} %'.format((accuracy_score(test_y2,model_random_forest2.predict(test_x2))*100).round(2)))

     La precisión de train para predecir si lloverá mañana es 99.98 %
     La precisión de prueba para predecir si lloverá mañana es 84.06 %
```

Estos resultados indicaron que existe una gran probabilidad de que llueva el día de mañana.

Link dataset:
https://www.kaggle.com/datasets?search=weatherAUS.csv

Link repositorio Github:
https://github.com/GarciaGtz/GarciaGtz-ProyectoFinalAAII_GarciaJuan.git

8. Conclusiones

Al comienzo de esta práctica se tenía previsto dos modelos, regresión logística y random forest, se buscó un dataset que presentara una problemática sobre un tema interesante, es por ello que se decidió seleccionar el tema del clima, donde en los último tiempos este a sido dañado severamente por los niveles de contaminación, al aplicar estos modelos se obtuvieron resultados de las predicciones muy buenos de ambos, pero cabe señalar que existen una ligera diferencia entre random forest y regresión logística, resultado como mejor modelo el primero mencionado.
Al desarrollar esta práctica logré establecer y mejorar aún más mi conocimiento sobre el aprendizaje automático y de de una problemática real general una predicción que mejore distintas situaciones, ya sea prevención o mejoramiento de una situación.

El resultado de este proyecto fue predecir en base al conjunto de datos, si en Australia lloverá el día de mañana, los resultados fueron los óptimos para indicar que random forest es eficiente el implementarlo para generar estas predicciones.

9. Referencias

Brownlee, J. (2021, 17 enero). *SMOTE for Imbalanced Classification with Python*. Recuperado 11 de diciembre de 2022, de https://machinelearningmastery.com/smote-oversampling-for-imbalanced-classification/

pandas. (s. f.). *pandas.Series — pandas 1.5.2 documentation*. Recuperado 11 de diciembre de 2022, de https://pandas.pydata.org/docs/reference/api/pandas.Series.html

scikit-learn. (s. f.). *sklearn.preprocessing.LabelEncoder*. Recuperado 11 de diciembre de 2022, de

https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.LabelEncoder.html

Zach, Z. (2021, 7 junio). *How to Calculate Z-Scores in Python*. Statology. Recuperado 11 de diciembre de 2022, de https://www.statology.org/z-score-python/